

1. Typ zadania

Projekt realizuje zadanie regresji, w którym sieć neuronowa przewiduje ciągłą zmienną wyjściową `performance_index` (0–100). Celem jest określenie zależności między codziennymi nawykami studentów a ich wynikami akademickimi.

2. Opis zestawu danych

W projekcie został wykorzystany syntetyczny zbiór danych pochodzący z platformy Kaggle, przedstawiający czynniki wpływające na wyniki egzaminów studentów. Zestaw danych zawiera 9776 obserwacji, z których każda reprezentuje jednego studenta oraz opisuje jego zachowania edukacyjne, nawyki związane z nauką, styl życia oraz warunki egzaminacyjne. Pozwala to analizować wpływ codziennych czynników na osiągnięte rezultaty akademickie. Spośród dostępnych cech zawartych w zbiorze do dalszej analizy i budowy modelu wybrano następujące cechy wejściowe (X):

- liczba godzin nauki (`study_hours`);
- liczba godzin snu (`sleep_hours`);
- poziom stresu (`stress_level`);
- frekwencja na zajęciach (`attendance_rate`);
- spożycie kofeiny (`caffeine_intake`).

Dobór zmiennych został podyktowany chęcią ograniczenia złożoności modelu i skupienia się na najistotniejszych czynnikach.

W realizowanym modelu zmienną wyjściową jest `performance_index`, czyli ogólny wskaźnik efektywności akademickiej studenta w danym tygodniu semestru w skali 0-100. Jest on obliczany jako ważona kombinacja wyników quizów i prac zaliczeniowych, uwzględniająca zarówno wiedzę teoretyczną, jak i systematyczność pracy. Wartość `performance_index` zależy od wszystkich pięciu zmiennych wejściowych oraz od ukrytej zmiennej opisującej efektywność uczenia się i poziom zmęczenia studenta.

Dane zostały podzielone w następujący sposób:

- 80% - zbiór treningowy (`x_train`, `y_train`)
- 20% - zbiór testowy (`x_test`)
- 10% z `x_train` – zbiór walidacyjny

3. Architektura sieci i proces uczenia

a) Model prosty

- Typ sieci – Multi-Layer Perceptron (MLP)
- Liczba wejść: 5 cech
- Warstwy ukryte:

- Dense 32 neuronów, aktywacja ReLU
- Dense 16 neuronów, aktywacja ReLU
- Dense 8 neuronów, aktywacja ReLU
- Warstwa wyjściowa: 1 neuron, aktywacja liniowa - przewiduje performance_index
- Optymalizator: Adam
- Funkcja straty: MSE (Mean Squared Error)
- Metryka: MAE (Mean Absolute Error)
- Liczba epok: 100
- Batch size: 16
- Czas uczenia: 2 minuty

b) Model zaawansowany

- Typ sieci – Multi-Layer Perceptron (MLP) z regularyzacją i normalizacją
- Liczba wejść: 5 cech
- Warstwy ukryte:
 - Dense 128 neuronów, aktywacja ReLU, BatchNormalization, Dropout 0.2, regularizacja L2 0.001
 - Dense 64 neuronów, aktywacja LeakyReLU($\alpha=0.1$), BatchNormalization, Dropout 0.2, regularizacja L2 0.001
 - Dense 32 neuronów, aktywacja LeakyReLU($\alpha=0.1$), BatchNormalization, Dropout 0.1, regularizacja L2 0.001
- Warstwa wyjściowa: 1 neuron, aktywacja liniowa - przewiduje performance_index
- Optymalizator: Adam, learning rate = 0.0005
- Funkcja straty: MSE (Mean Squared Error)
- Metryka: MAE (Mean Absolute Error)
- Liczba epok: 300
- Batch size: 32
- Dodatkowe mechanizmy:
 - EarlyStopping (patience=20, restore_best_weights=True)
 - ReduceLROnPlateau (monitor=val_loss, factor=0.5, patience=10, min_lr=1e-6)
- Czas uczenia: 6 minut

4. Obserwacje i wnioski

Wyniki modeli:

Model	Test MSE	Test MAE
Prosty	21.34	3.71
Zaawansowany	20.45	3.64

Analiza wyników wykazała, że oba modele osiągnęły zbliżoną dokładność predykcji. Prosty model charakteryzuje się szybkim i stabilnym procesem uczenia, natomiast zaawansowany model, mimo dłuższego czasu treningu, uzyskał minimalnie niższe wartości MSE i MAE, co

wskazuje na lepsze dopasowanie do danych i zdolność modelowania bardziej złożonych zależności.

Podsumowując, prosty model jest wystarczająco skuteczny dla tego zbioru danych, zapewniając stabilne predykcje w krótszym czasie, natomiast zaawansowany model może być korzystny przy większych lub bardziej złożonych zbiorach danych, gdzie dodatkowa regularyzacja i większa liczba neuronów poprawiają dokładność predykcji.